胡杨林基金

中国科学技术大学
University of Science and Technology of China

面向场景的虚拟机自动调优技术

报告人 张昱、丁伯尧

张昱课题组(yuzhang@ustc.edu.cn)
中国科学技术大学 计算机科学与技术学院

2026.1.16

研究进展（2025.12-2026.1）

- 针对V8虚拟机参数配置的实证分析
  - 完成参数影响性分析，基于结果筛选出171个需要调优的参数
  - 训练数据集的收集：基于不同目标场景进行数据集收集
- 离线调优器
  - 性能预测模型的设计与实现
    - 基于MLP的性能预测模型
    - 基于随机森林的性能预测模型
  - 基于代码缓存进行的离线调优流程设计

研究内容一：虚拟机配置参数的实证分析

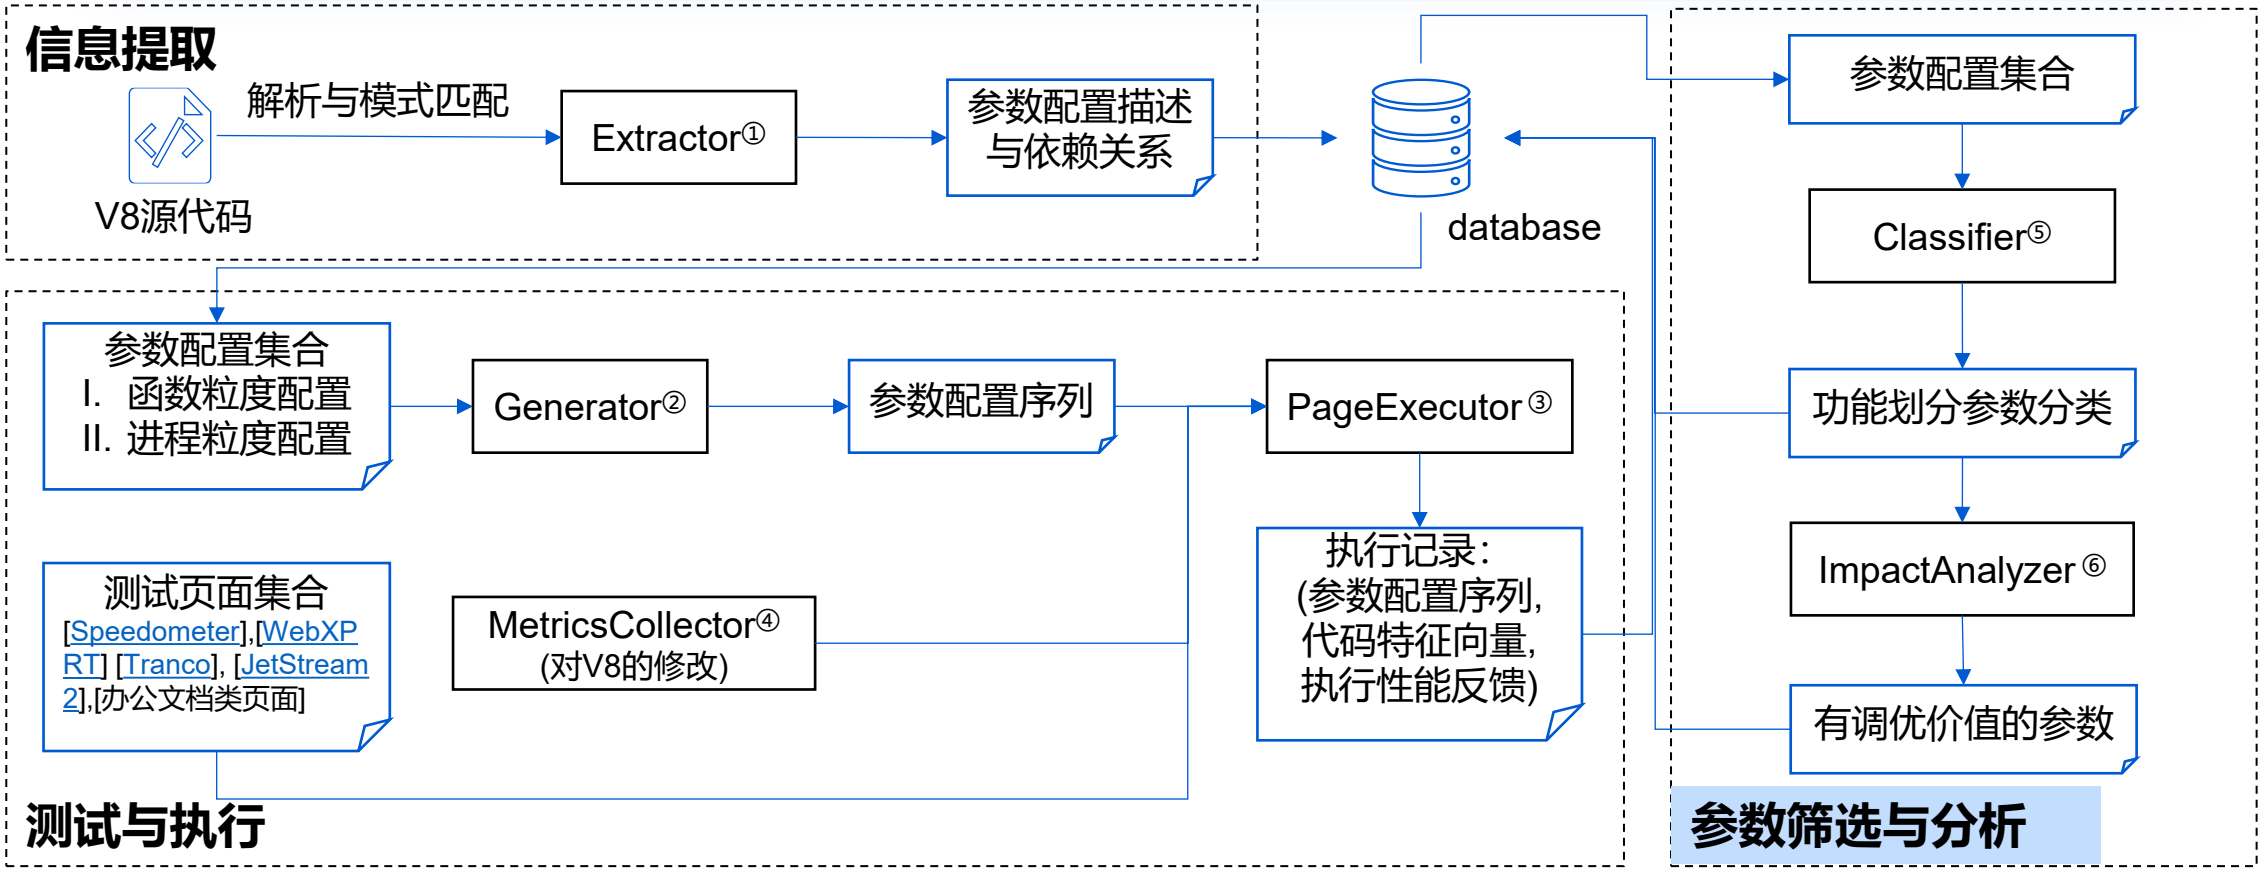

目标： 确定调优的目标**参数配置集合**；收集用于性能模型训练的**数据集**

进展：完善测试与执行框架，完成参数筛选与分析

参数筛选与分析

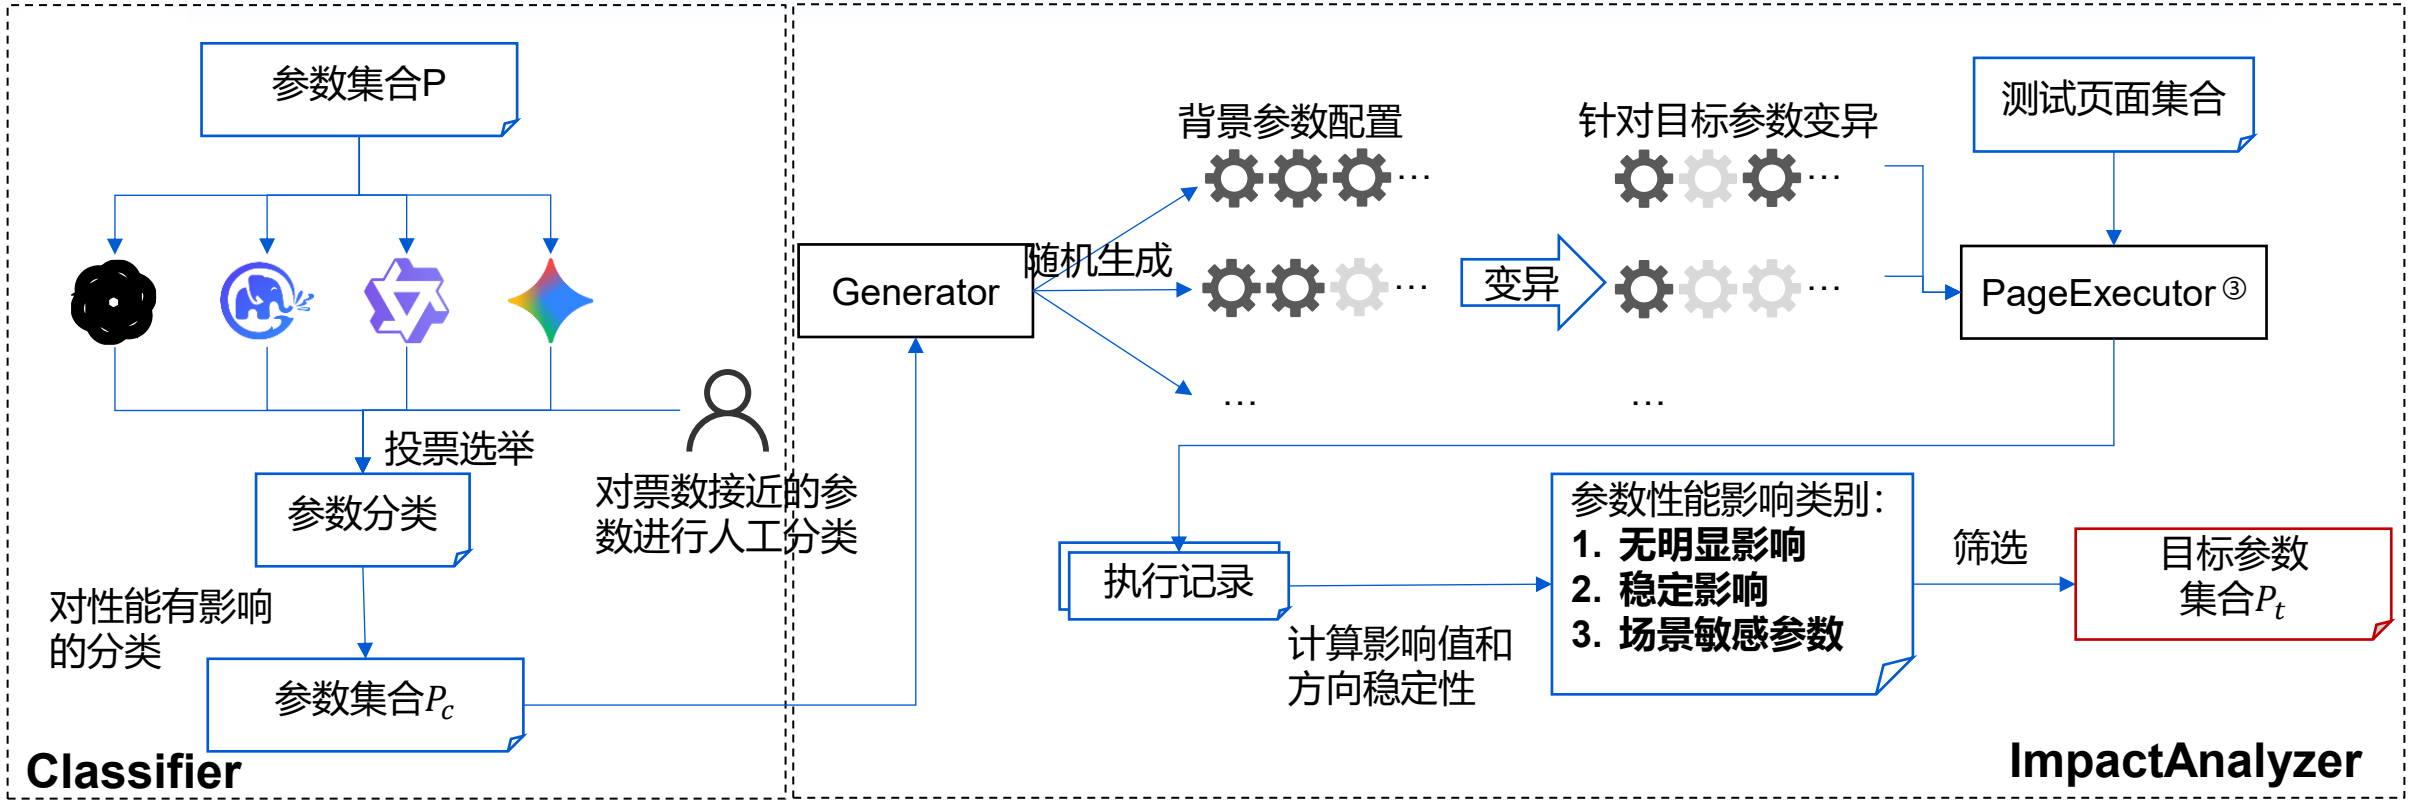

- **Classifier**: 利用LLM和人工分析对参数进行功能分类
- **ImpactAnalyzer**：基于实证结果分析参数对性能的影响，进一步筛选调优目标参数配置集合

ImpactAnalyzer: 参数影响性分析

参数影响值(impact_value)：用于衡量参数对性能的影响

基线性能：$\mathrm{P}_{(p,default)}(C_j, \mathrm{conf}_i)$

参数p变异为值v后的性能：$\mathrm{P}_{(p,v)}(C_j, \mathrm{conf}_i)$

在场景C_j和配置conf_i下的影响值：

$$impact_p(C_j, \mathrm{conf}_i) = \max_v\{\frac{|\mathrm{P}_{(p,v)}(C_j, \mathrm{conf}_i) - \mathrm{P}_{p,default}(C_j, \mathrm{conf}_i)|}{\mathrm{P}_{p,default}(C_j, \mathrm{conf}_i)}\}$$

参数P的**影响值**：$impact_p = \mathrm{mean}_{i,j}\{impact_p(C_j, \mathrm{conf}_i)\}$

方向稳定性(stability_value): 用于衡量参数不同取值对性能的影响是否一致

参数p在场景C_j和配置conf_i的最佳取值：

$$\mathrm{best}_p(C_j, \mathrm{conf}_i) = \mathrm{argmin}_v\{\mathrm{P}_{(p,v)}(C_j, \mathrm{conf}_i)\}$$

对于p的取值，在M个场景×N个配置下的测试中，取值为v的时候性能最好的测试用例数量记为$numBest_v$

参数P的**方向稳定性**：$stability_p = \frac{\max_v\{numBest_v\}}{\mathrm{M}\times\mathrm{N}}$

基于参数影响值和方向稳定性的分类：

1. **无明显影响：**(impact_value < threshold)
2. **稳定影响：**(impact_value >= threshold，且stability_value >= stable_threshold)
3. **场景敏感参数：**(impact_value >= threshold, 且stability_value < stable_threshold)

⇩

选择场景敏感参数作为调优目标

ImpactAnalyzer: 参数影响性分析

- 参数影响分析的一些测试设置
  - 测试场景集合：octane数据集中的7个测试程序(‘richards’, ‘box2d’, ‘deltablue’, ‘crypto’, ‘pdfjs’, ‘typescript’, ‘zlib’)；2个办公类场景
- 背景参数配置序列数量：3个
- 性能测试方式：重复执行目标程序5次，取性能平均值
- 结果：impact>0.03, stability < 0.85筛选出**171**个参数

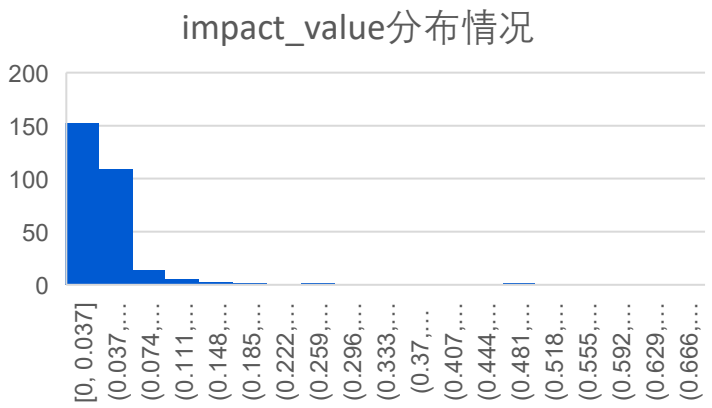

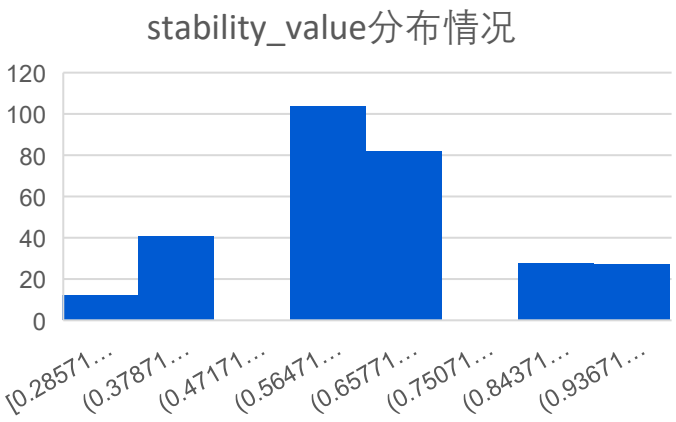

parameter	impact	stability	dominant_value
use-ic	0.701733	1	TRUE
maglev-as-top-tier	0.491761	1	FALSE
turboshaft	0.487182	0.857143	TRUE
gc-global	0.407451	0.857143	FALSE
max-valid-polymorphic-map-count	0.366575	0.285714	4
turbo-inlining	0.277344	0.714286	TRUE
concurrent-recompilation	0.277133	0.857143	TRUE
lite-mode	0.224381	1	FALSE
disable-optimizing-compilers	0.219735	1	FALSE
maglev-loop-peeling-max-size	0.209902	0.285714	200

研究内容二：离线调优器的设计与实现

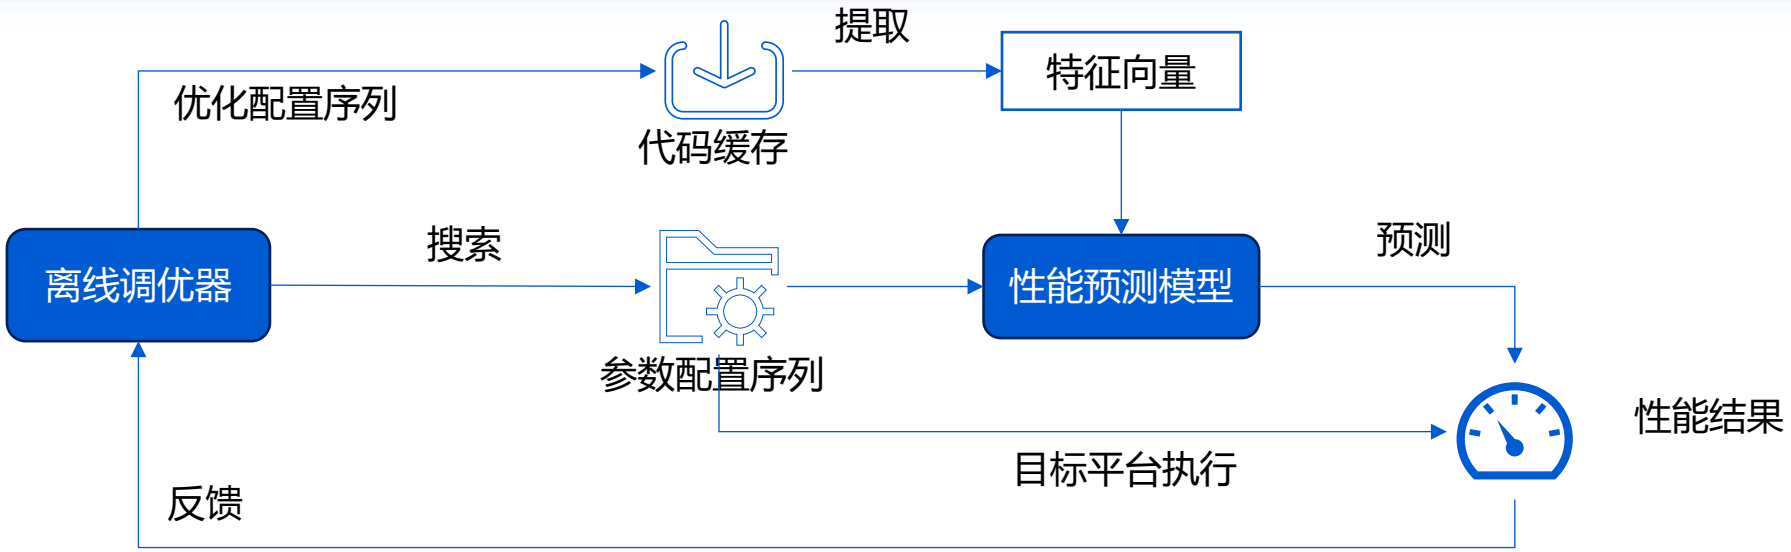

目标：以**离线**的形式对目标程序进行**进程粒度配置**的调优

- **离线调优器**：离线形式进行优化配置序列的搜索和生成
  - 基于OpenTuner[1]，支持遗传算法、粒子群、随机搜索等策略
  - 生成代码缓存时同时写入特征向量
  - 将搜索得到的优化配置序列写入代码缓存，以支持下次执行时使用目标配置启动

- **性能预测模型**：给定**代码特征向量**与**参数配置序列**，输出其相较于默认配置下的性能的**加速比**
  - 用于加速搜索过程，避免执行带来的高开销

- 模型预测和目标平台执行相结合
  - 在目标页面被执行之后，可以利用实际执行反馈代替模型预测进行更精确的搜索

[1] Ansel J, Kamil S, Veeramachaneni K, et al. Opentuner: An extensible framework for program autotuning[C]//Proceedings of the 23rd international conference on Parallel architectures and compilation. 2014: 303-316.

基于代码缓存的离线调优

利用代码缓存传递特征向量与参数配置

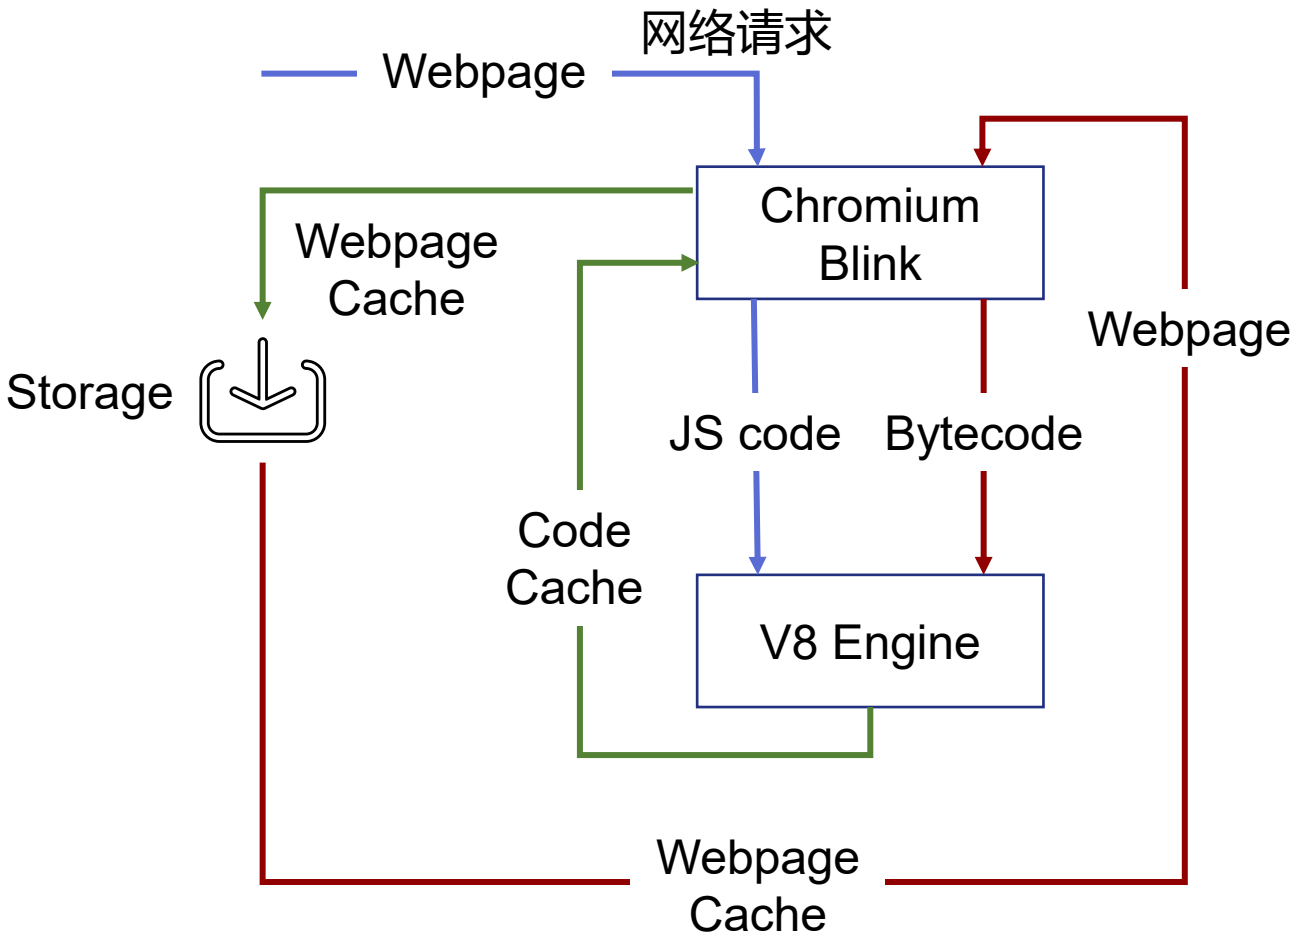

基于代码缓存的离线调优

利用代码缓存传递特征向量与参数配置

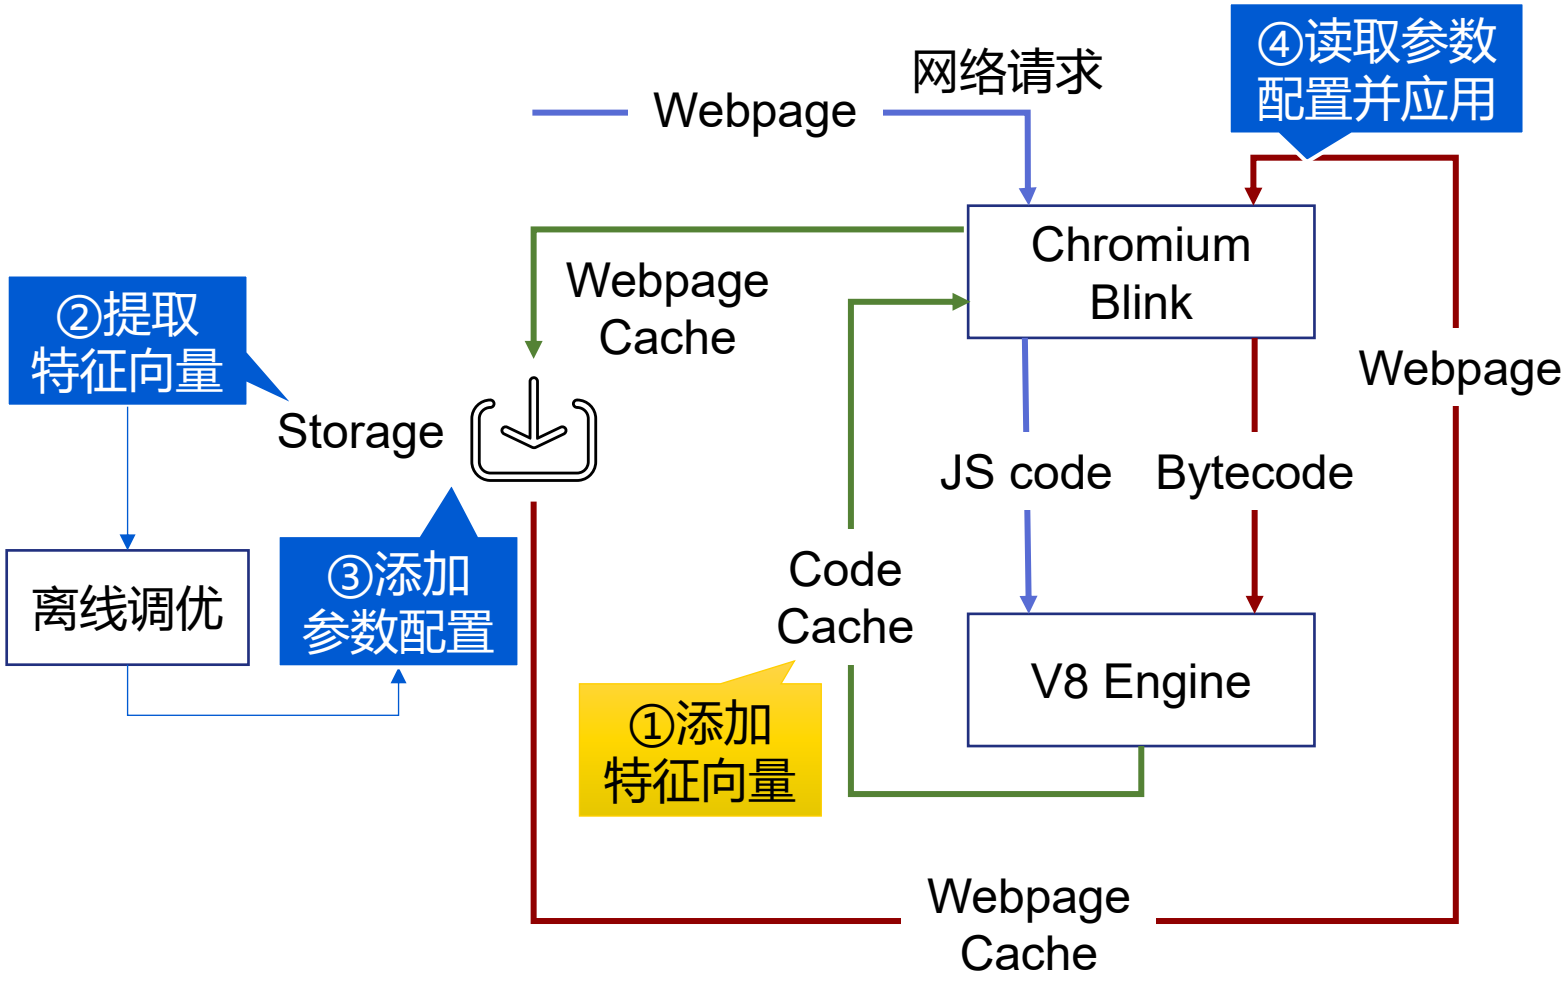

1. 修改V8代码缓存生成机制（实现中）
   - V8会将内部结构SharedFunctionInfo序列化作为代码缓存
   - 通过在SharedFunctionInfo中定义新的数据结构以实现对特征向量的记录
   - 特征向量可以包含运行时信息
2. 通过Chromium的页面缓存提取特征向量用于离线调优
3. 将离线调优结果写入页面缓存中
4. 通过页面缓存读取调优配置用于执行

基于MLP的性能预测模型的实现与评估

基于MLP的性能预测模型

- turbo-inlining
- use-osr
- compact-on-every-full-gc
- inline-new
- max-optimized-bytecode-size
- max-inlined-bytecode-size
- invocation-count-for-maglev
- invocation-count-for-turbofan
- min-semi-space-size
- stack-size
- baseline-batch-compilation-threshold

参数配置集合

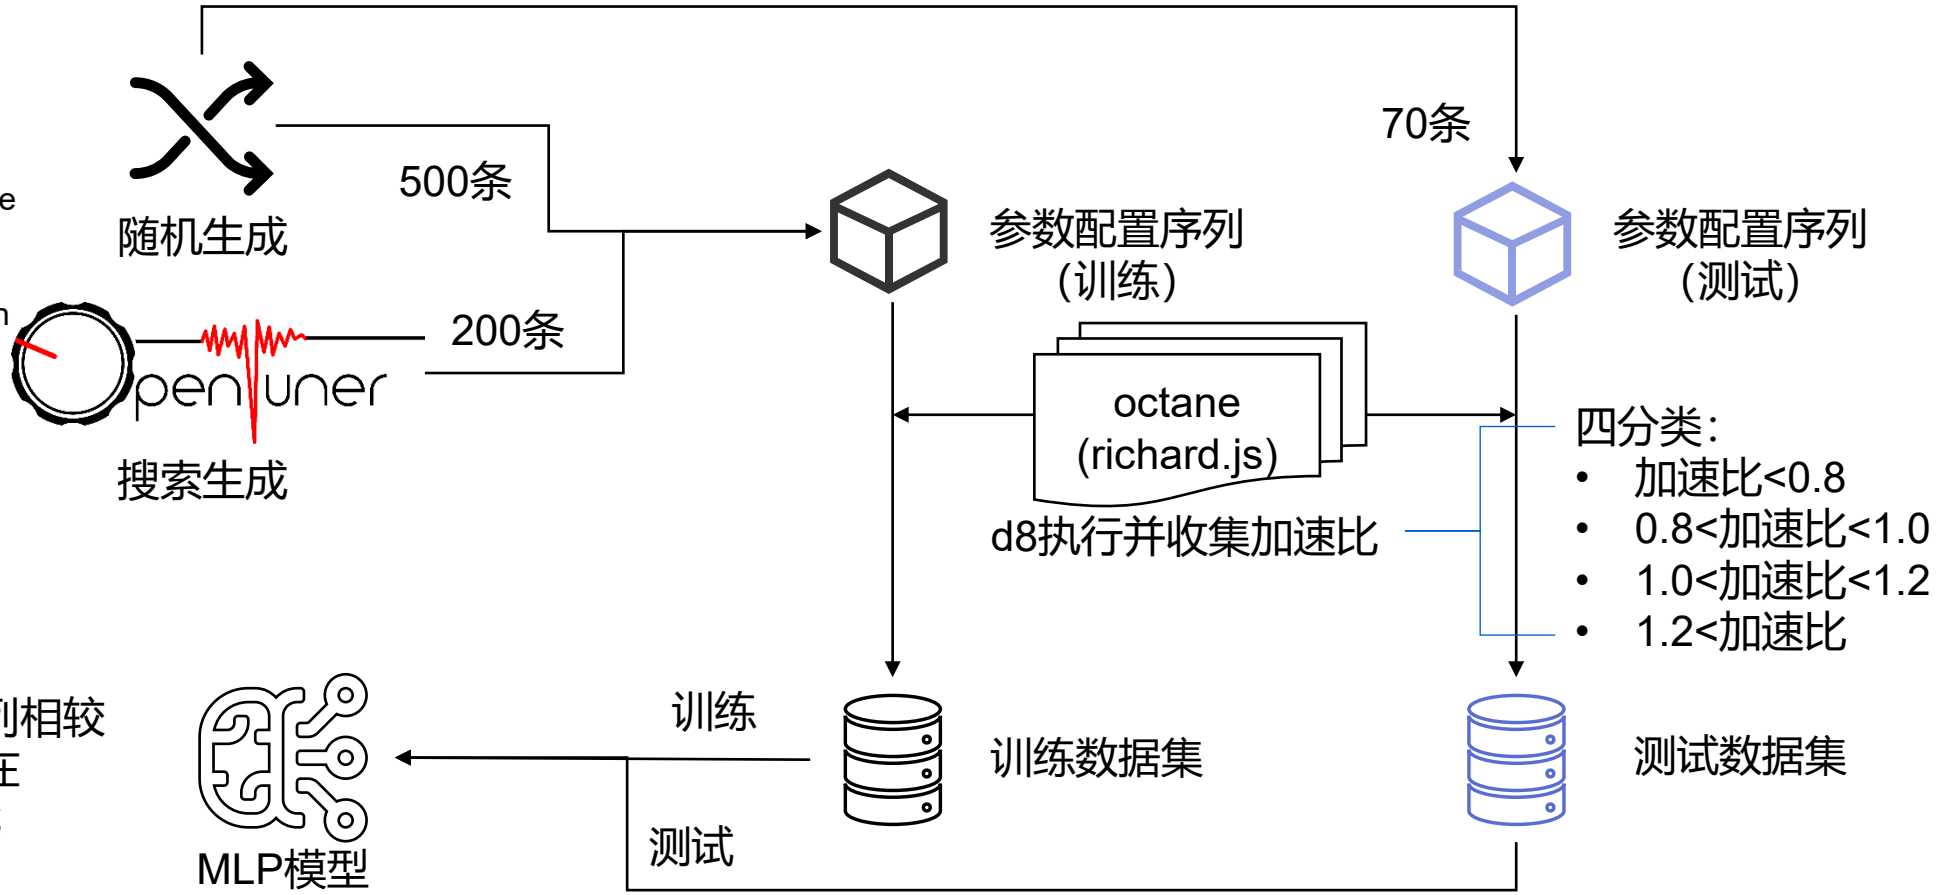

输入：**参数配置序列**
输出：该参数配置序列相较于默认参数配置序列在richards.js下的**加速比**

测试结果：

accuracy	precision	recall	f1 score
80.3%	81.5%	80.3%	80.6%

scripts/mlp · main · proj / JSTuner / ccfhw2025 · GitLab

基于多段式学习的随机森林性能预测模型的实现与评估

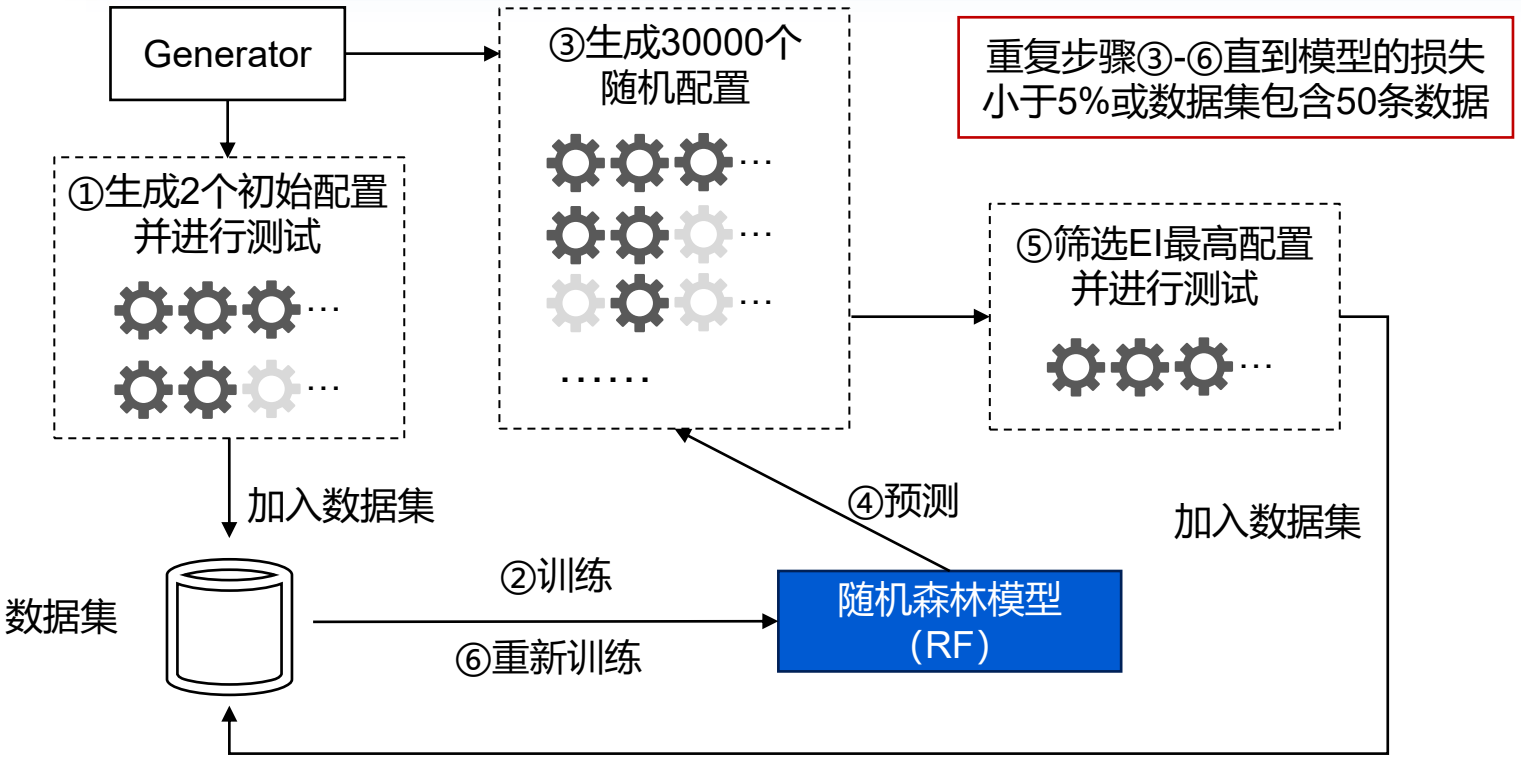

EI(Expected Improvement): 用于衡量一个点相对于当前已知最优值的预期提升

$$EI(c) = \left(f' - \mu(c)\right)\Phi(Z) + \sigma(c)\phi(z),$$

其中$Z = \frac{f'-\mu(c)}{\sigma(c)}$, f'当前的最优值, $\mu(c)$和$\sigma(c)$表示所有RF子树中预测值的平均值和方差， $\Phi(Z)$和$\phi(z)$则分别表示累积分布和概率密度

- 基于**贝叶斯优化**的思想，利用多阶段的重复学习筛选高质量数据集，减少对大量数据集的依赖
- 利用该模型直接预测**目标配置相较于默认配置的加速比**
- 完成模型训练后同样使用70条数据进行测试，在针对octane数据集richards测试用例中该方法训练的模型平均损失（$\mathrm{Avg}\frac{|\text{预测的加速比}-\text{测试的加速比}|}{\text{测试的加速比}}$）为**8.57%**

模型训练总结

两个模型的对比

模型	准确率	训练数据量	训练耗时	优点	缺点
多层感知机 MLP	80.3%	700条	训练耗时本身较短，多数时间用于收集数据集	• 模型**实现简单** • 更容易**扩展到高维度的输入**	• 对于**数据集的质量要求比较高**。由于是分类问题，要求数据集尽可能地在四种分类下平均 • 回归模型对**数据集的需求量较大**，理论上需要数十倍参数量的数据；为了降低这一需求只能退而求其次选择分类模型
随机森林 RF	91.43%	50条	训练时间较长	• 模型对于高质量的**数据集需求低** • 更加**适合回归模型**	• 贝叶斯优化方法在高维度输入上表现不好，可能出现**维度灾难**

其他问题与风险

- 当前只采用了**10个参数**作为输入，空间较小，**在高维度输入时可能呈现不同的结果**
- 为了排除代码特征选取导致的差异，上述两个模型训练时没有加入特征向量进行训练，而是针对不同参数配置在单个程序下的性能预测问题进行训练，这种方式得到的模型**只对单个程序有效**
- 加入特征向量后可能会由于特征选取不具有代表性而产生**过拟合**的问题

1月-2月计划

研究内容二：离线调优器

- 完成对V8和Chromium中代码缓存部分相关的修改，支持利用代码缓存进行离线调优
- 进一步进行性能预测模型的训练和调整
  - 在当前的模型中加入特征向量
  - 扩大输入参数向量的规模与数据集规模进行进一步地训练与测试
  - 基于模型的结果调整特征选取
- 实现离线调优器的主要代码框架

研究内容三：在线调优器

- 配置预测模型的训练：基于调研结果进行配置预测模型的选型，并进行初步实验